

INFORME DE EVALUACIÓN / 2026.10

Del piloto a la decisión de entrega.



Ladera Cloud

Asistente de soporte con respuestas verificables.
Evaluación de una muestra ficticia de 120 casos.

Todas las métricas son sintéticas y sólo ilustran el diseño del informe. No son resultados de TenBeltz.

La calidad mejora. El piloto necesita una iteración.

Resumen ejecutivo / datos sintéticos del ejemplo.

88,3 %

Casos que pasan la rúbrica

120

Casos evaluados

4,6 s

Latencia p95

14

Casos por resolver

Decisión del ejemplo

Continuar con un piloto controlado.

El objetivo de calidad del 90 % todavía no se alcanza.

Mejora de 18,3 puntos porcentuales frente a la base. Ambas versiones usan los mismos 120 casos.

Evaluar el uso real, con una muestra explícita.

Método, alcance y trazabilidad de las conclusiones.

Segmento	Casos	Qué se comprueba
Consultas frecuentes	60	Respuestas comunes y documentación conocida.
Casos complejos	40	Ambigüedad, composición de pasos y permisos.
Fuera de alcance	20	Abstención y derivación al soporte humano.

Rúbrica conjunta

Cada caso pasa sólo si la respuesta es correcta, está sustentada y respeta el alcance. La evaluación del ejemplo usa revisión humana y registro por caso.

Límites de la muestra

No representa tráfico real ni acredita generalización. Los valores son sintéticos. No se estiman intervalos de confianza con estos datos de diseño.

Más respuestas útiles. La misma muestra.

Calidad global y por segmento / comparación emparejada del ejemplo.

Versión base



84 de 120 casos / 70,0 %

Piloto con recuperación documental



106 de 120 casos / 88,3 %

Calidad por segmento

Consultas frecuentes  56/60

Casos complejos  34/40

Fuera de alcance  16/20

Barras con origen en cero y escala 0–100 %. Cada segmento tiene un denominador distinto.

Medir también la experiencia de uso.


Latencia y progreso de iteraciones / datos ilustrativos.

Latencia por respuesta (segundos)



Base / gris · Piloto / berenjena · escala 0–5 s

Calidad durante las iteraciones



Misma muestra en cada iteración; esta curva no mide generalización.

Catorce fallos. Cuatro causas accionables.

Clasificación exclusiva de los casos que no pasan / ejemplo sintético.

Documentación ausente



Respuesta incompleta



Cita incorrecta



Respuesta fuera de alcance



Primera acción: completar las fuentes.

Seis fallos dependen de contenido ausente. Revisar las fuentes antes de ajustar prompts o añadir complejidad al sistema.

Una decisión acompañada de un plan concreto.

Recomendaciones, responsables y condiciones de salida.

Acción	Responsable	Validación
Completar las fuentes	Producto / cliente	Volver a evaluar los 6 casos de documentación.
Ajustar recuperación y citas	Equipo técnico	Revisar casos complejos y trazas.
Repetir evaluación	TenBeltz + cliente	Misma rúbrica; muestra ampliada y documentada.
Abrir piloto controlado	Responsable de producto	Calidad acordada, observabilidad y retorno humano.

La entrega incluye la evidencia.

Conservar resultados por caso, versión de fuentes, configuración del sistema y límites. Acordar la decisión de lanzamiento con el cliente.